Phase 3A-3: LockNest 自适应机制实验验证

机制、性能、压力与稳定性实验



默认 `-O 8 -A` 通过重复实验；计数器记录解释了小 `Q` 的退化；多热点锁实验未出现 map failure 或 zero-progress。

Result root: `results/phase3a3_locknest_20260731_1435_budget`

一句话结论

+3.18%	-5.32%	0	0
safe adaptive TPS vs baseline	safe adaptive p99 vs baseline	formal failures	map update failures

实验结果： `-O 8 -A` 是当前 LockNest 默认候选，3×60s 重复实验无失败、无性能退化，计数器记录解释了参数变化的影响。

需要写克制： finite `Q`、promotion `P`、expiry tuning 不应被写成默认性能优化；它们更适合 stress/ablation 和边界保护。

为什么 Phase 3A-3 必须做

研究问题

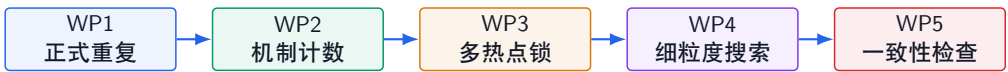
- 参数是不是经验拍脑袋？
- 多热点锁是否导致单锚点聚集？
- 1024-entry map 是否会溢出或抖动？
- TPS/p99 背后有没有机制证据？
- 正式重复是否稳定，而不是挑样本？

Phase 3A-3 的回答

- 用 formal repeats 证明候选默认配置稳定。
- 用 counters 解释 locality、fallback、stale 和 pressure。
- 用 multi-hot microbench 单独压力测试多热点锁。
- 用 fine search 补中间参数点，避免粗扫漏判。
- 用全目录错误扫描排除 runtime failure。

这一步的目标不是“找一个最高 TPS 点”，而是把 LockNest 自适应从可运行机制推进到可投稿证据链。

实验设计



证据合同： default candidate 必须满足性能不劣化、尾延迟不过界、机制 counters 可解释、压力实验无失控、运行时无异常退出。

TPS / p99 / CV | locality / fallback | zero-progress / map fail | Q/C/E/N/P trend | no stall / disabled

先解决运行时安全前提



修复不是 LockNest 调参

- failure 同时出现在 `baseline_off` 与 `safe_adaptive`。
- 因此根因属于组合调度器进度边界。
- 修复后再重跑 Phase 3A-3，避免把 runtime stall 误归因到 LockNest。

修复后全矩阵未再出现 runnable stall，最终 `sched_ext=disabled`。

运行时安全公式

原始强 boost

$$slice'(p) = \infty$$

- owner 进度最强；
- 但最坏情况下可能压制无关 runnable task；
- 与 per-CPU kworker 的进度要求冲突。

当前有限预算

$$slice'(p) = \min\{slice(p) + B \cdot S_{\mathrm{dfl}},\ M \cdot S_{\mathrm{dfl}}\}$$

$$B = 1, \quad M = 2$$

- 保留 owner-progress；
- 给系统线程留下进度边界；
- 为 Phase 3B 的公平性实验留下 knob。

本页属于正式实验前提：它让 LockNest 参数实验可重复，不是 Phase 3A 的性能收益来源。

实验设置与产物

项目	设置
Kernel	Linux 6.17.0-35-generic
DB	MariaDB 10.11.14
Workload	Sysbench OLTP read-write
Dataset	16 tables, 1M rows/table
Threads	256
Owner offset	`-O 8`
Scheduler	`scx_lockcoop`

产物	内容
`formal_repeats.csv`	8 个关键 profile，3×60s
`mechanism_evidence.csv`	locality/fallback/stale/ counters
`multihot_microbench_summary.csv`	1–64 个热点锁压力测试
`fine_search.csv`	21 个细粒度参数点
`summary.md`	自动汇总表

所有结果来自修复后的 Phase 3A-3 结果根目录：`phase3a3_locknest_20260731_1435_budget`。

验收标准

性能边界

$$\Delta_{\mathrm{TPS}} = \left(\frac{\mathrm{TPS}_A}{\mathrm{TPS}_{base}} - 1 \right) \times 100\%$$

$$\Delta_{\mathrm{p99}} = \left(\frac{\mathrm{p99}_A}{\mathrm{p99}_{base}} - 1 \right) \times 100\%$$

$$\mathrm{TPS}_A \geq 0.95 \cdot \mathrm{TPS}_{base}, \quad \mathrm{p99}_A \leq 1.10 \cdot \mathrm{p99}_{base}$$

稳定性边界

$$failures = 0, \quad map_update_fail = 0$$

$$zero_progress_threads = 0$$

$$sched_ext_state_{\mathrm{after}} = \mathrm{disabled}$$

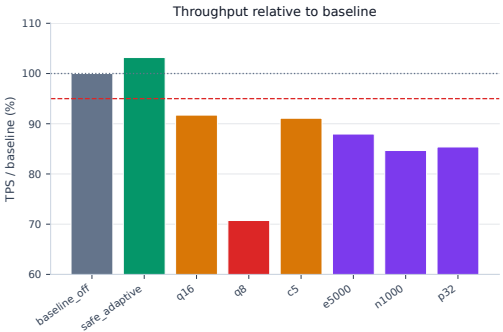
Phase 3A-3 分别检查性能、机制、压力下的表现与运行时状态。

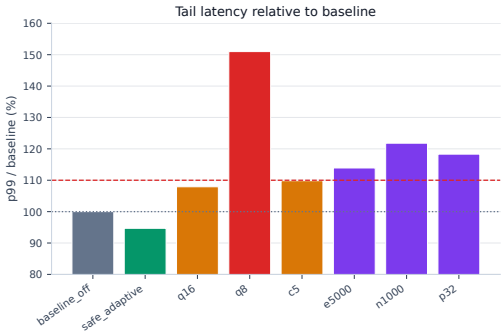
正式重复 profile 设计

Profile	参数	目的
`baseline_off`	`-O 8`	默认 owner 观测路径，不打开 LockNest adaptive
`safe_adaptive`	`-O 8 -A`	候选主配置：保留 same-lock anchor，不限制 queue
`q16`	`-O 8 -A -Q 16`	中等 finite admission 压力
`q8`	`-O 8 -A -Q 8`	激进 queue cap 压力
`c5`	`-O 8 -A -Q 16 -R 4 -C 5`	cooldown 组合点
`e5000`	`-O 8 -A -Q 16 -R 4 -C 5 -e 5000 -N 5000`	长有效期组合点
`n1000`	`-O 8 -A -Q 16 -R 4 -C 5 -e 2000 -N 1000`	短 min-expiry 压力
`p32`	`-O 8 -A -Q 16 -R 4 -C 5 -e 2000 -N 2000 -P 32`	promotion 组合点

这些点不是为了穷举最优，而是覆盖 default、queue pressure、cooldown、expiry、promotion 五类机制。

WP1: 正式重复结果图





虚

线：TPS 95% 下界与 p99 110% 上界。只有 safe_adaptive 同时满足性能和尾延迟边界。

WP1: 正式重复数值表

Profile	n	fail	TPS	CV	p99 ms	TPS/base	p99/base
baseline_off	3	0	5227.74	4.83%	131.99	100.0%	100.0%
safe_adaptive	3	0	5394.09	3.31%	124.97	103.2%	94.7%
q16	3	0	4794.96	2.09%	142.43	91.7%	107.9%
q8	3	0	3697.65	2.32%	199.28	70.7%	151.0%
c5	3	0	4762.36	1.86%	144.99	91.1%	109.9%
e5000	3	0	4597.78	1.74%	150.34	87.9%	113.9%
n1000	3	0	4426.28	4.87%	160.76	84.7%	121.8%
p32	3	0	4463.14	4.58%	156.16	85.4%	118.3%

正式重复给出主结论：默认 `-A` 不劣化；有限 admission 组合点不应作为默认配置。

正式结果的三个读法

默认候选成立
`safe_adaptive` TPS 103.2%，p99 94.7%，failure 0。

小 Q 有代价
q8 TPS 70.7%，p99 151.0%，不能默认。

组合 knob 是 stress
`C/e/N/P` 组合没有超过默认 `-A`。

论文表述

LockNest adaptive 限制锚点控制的作用范围，并通过压力实验验证稳定性。默认路径保留 same-lock locality；压力实验分别测量保护措施的作用及代价。

LockNest 决策路径



counters: `locality hit/fallback`, `pressure`, `cooldown`
`prevcpu fb/default fb`, `stale`, `map fail`

自适应规则：状态与公式

锚点新鲜度

$$fresh(L,t) = \mathbb{1}\{t - last_update_L \le T_L\}$$

$$T_L \in [N,\ X]$$

admission 判定

$$admit(L,c) = idle(c) \vee queued(c) < Q$$

pressure path

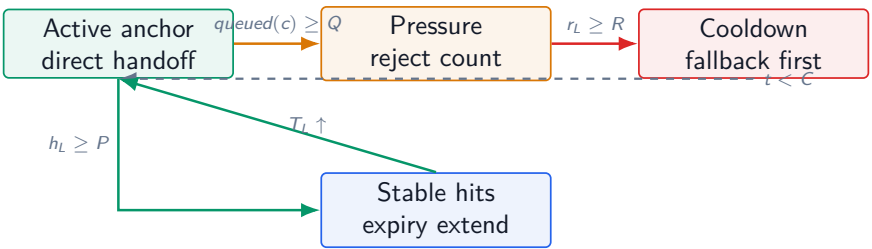
$$r_L \leftarrow r_L + 1$$

$$r_L \ge R \Rightarrow \begin{cases} cooldown_until_L \leftarrow t + C \\ T_L \leftarrow \max(N,\ T_L/2) \end{cases}$$

promotion path

$$h_L \ge P \Rightarrow T_L \leftarrow \min(X,\ 1.5\,T_L)$$

自适应状态机



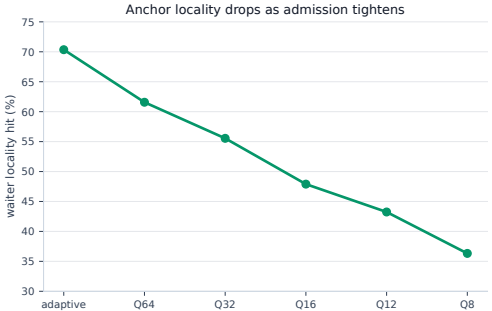
设计意图：默认路径少决策、少写 map；只有 pressure evidence 连续出现时才进入 fallback-heavy 控制。

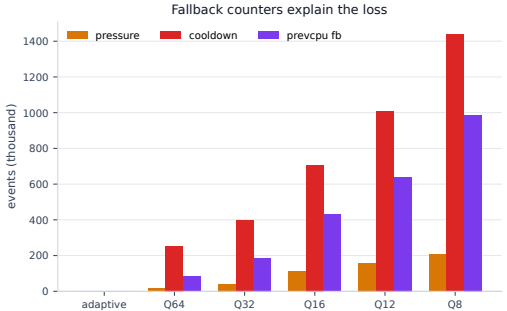
WP2: 机制证据表

Profile	Locality	Waiter loc.	Pressure	Cooldown	Prevcpu fb	Default fb	Stale	Map fail
`baseline_off`	31.24	69.56	0	0	0	2,804,135	75,057	0
`safe_adaptive`	31.75	70.35	0	0	0	3,062,059	66,801	0
q64	29.85	61.57	14,961	253,866	83,334	3,304,994	102,885	0
q32	28.01	55.55	41,452	400,215	186,869	3,368,961	116,823	0
q16	27.79	47.90	111,919	707,068	430,951	3,145,199	161,466	0
q12	26.82	43.24	157,509	1,011,008	640,605	3,028,957	174,843	0
q8	24.63	36.33	205,896	1,436,608	985,702	2,649,129	184,268	0
p18	29.07	49.70	248,864	549,354	402,737	3,174,497	154,981	0
p32	28.80	49.67	244,495	553,611	409,396	3,291,615	160,132	0

核心读法：小 `Q` 同时降低 waiter locality、增加 cooldown reject 和 prevcpu fallback；这直接解释 TPS/p99 退化。

WP2: Q-ladder 机制图





`adaptive` 为默认 `-A`；Q8 的 waiter locality 只有 36.33%，同时 cooldown reject 超过 143 万。

机制解释：为什么小 Q 变差

队列限制的收益

- 防止单个 anchor CPU 过载。
- 给默认调度器更多局部负载均衡空间。
- 在多热点分散时可能无害。

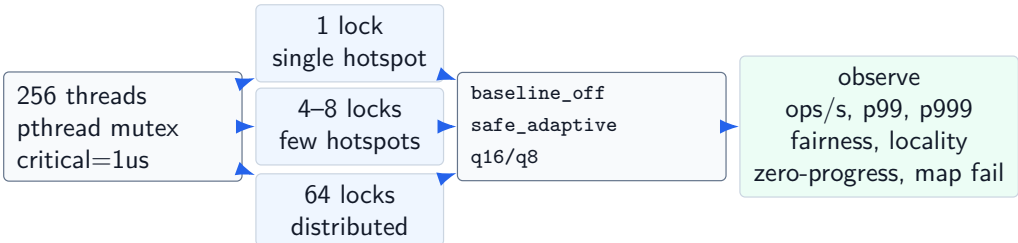
队列限制的代价

- 破坏 same-lock handoff 的缓存局部性。
- 产生 pressure/cooldown/prevcpu fallback 链式放大。
- 强热点锁下会把 tail latency 推到 ms 级。

$$Q\downarrow \Rightarrow \text{locality}\downarrow, \quad \text{fallback}\uparrow, \quad \text{p99}\uparrow, \quad \text{TPS}\downarrow$$

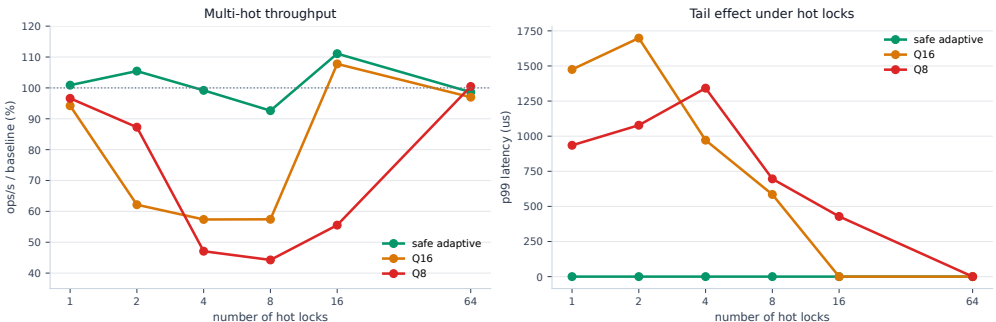
因此 `Q` 可以是压力路径候选，但不应该成为默认热路径上的固定小阈值。

WP3: 多热点锁实验设计



这个实验直接回答“多个不同热锁同时存在时，单 anchor 与 fallback 是否导致失衡或 map 失败”。

WP3: 多热点锁趋势图



safe_adaptive 没有引入 ms 级 tail；q8/q16 在少数强热点下 tail 明显放大。

WP3: 多热点锁关键数值

Locks	Profile	ops/s	ops/base	p99 us	zero-progress	map fail
1	safe_adaptive	916,548	100.9%	0.0	0	0
1	q16	856,023	94.2%	1475.0	0	0
1	q8	877,817	96.6%	935.0	0	0
4	safe_adaptive	3,255,308	99.2%	0.0	0	0
4	q16	1,882,702	57.4%	971.5	0	0
4	q8	1,545,212	47.1%	1342.0	0	0
16	safe_adaptive	12,679,476	111.1%	0.0	0	0
16	q16	12,300,197	107.8%	0.0	0	0
16	q8	6,339,389	55.5%	428.5	0	0
64	safe_adaptive	42,337,931	98.6%	0.0	0	0
64	q16	41,634,960	97.0%	0.0	0	0
64	q8	43,131,499	100.5%	0.0	0	0

多热点结论：没有观察到 map 容量崩溃或 zero-progress；退化集中在少数强热点 + 小 `Q`。

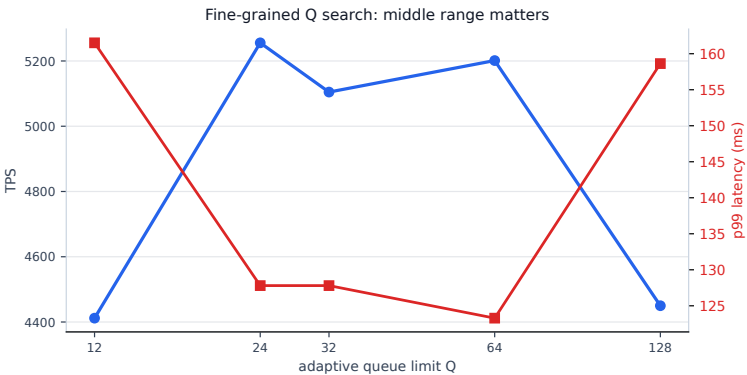
WP4: 细粒度搜索覆盖范围

参数族	本轮补点	回答的问题
Q	12, 24, 32, 64, 128	粗扫是否漏掉中间队列容量
C	2, 3, 8, 10, 15 ms	cooldown 是否需要精细调参
E/N	3000/3000, 4000/4000, 8000/8000, N=750/1500	anchor 生命周期边界
P	8, 12, 18, 20, 24, 48	promotion 是否有精确最优整数

解释口径

fine search 每个配置运行一次、持续 20s，用于观察参数趋势；WP1 采用 3×60s 重复实验。细粒度搜索补充测试了 18、24 等中间取值。

WP4: Q 细粒度曲线



Q=24/32/64 短测较好，但

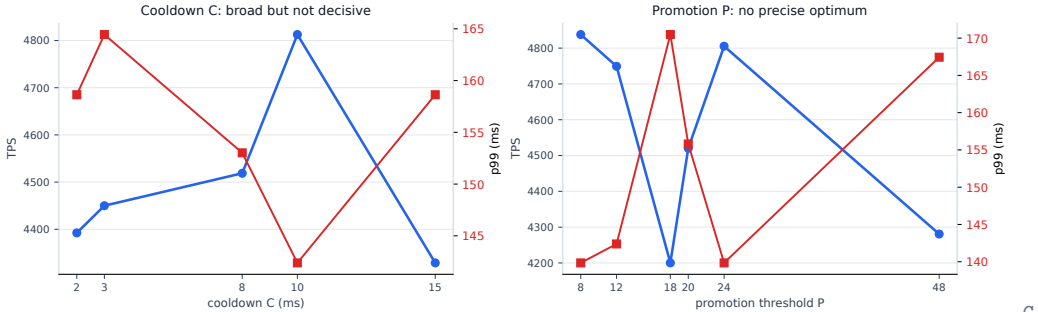
Q=128 与正式 Q=16/8 显示：queue cap 不能简单越大或越小。

WP4: Q 参数交叉验证

Profile	Fine TPS	Fine p99	Waiter locality	Cooldown reject	论文判断
Q64	5201.28	123.28	61.57%	253,866	stress 候选
Q32	5104.71	127.81	55.55%	400,215	stress 候选
Q24	5255.63	127.81	–	–	需要正式重复才写强
Q16	4794.96	142.43	47.90%	707,068	不做默认
Q12	4411.82	161.51	43.24%	1,011,008	不做默认
Q8	3697.65	199.28	36.33%	1,436,608	明确反例

结论不是“找到 Q=24 最优”，而是“小 Q 明确破坏 locality；中等 Q 只适合后续压力路径验证”。

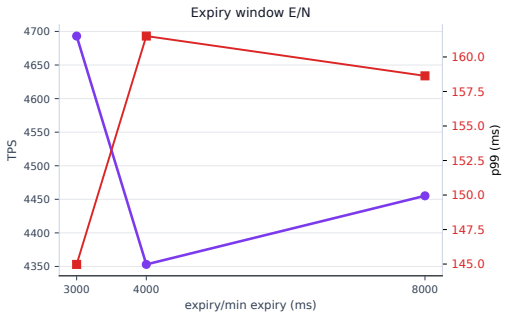
WP4: Cooldown 与 Promotion

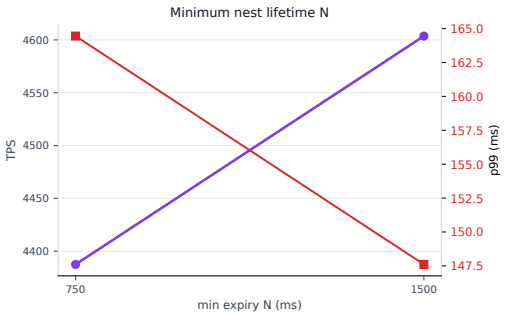


C

在 2–10ms 内对结果影响较小；已测试 P=18，该值并非最优点。

WP4: Expiry / Nest Lifetime





有

效期调整应保守：缩短用于防 stale，延长用于稳定局部性；当前数据不支持把 E/N 变成频繁在线调参对象。

参数分类：已实现 / 规划中 / 不建议自适应

类别	参数	当前策略	证据
已实现	`-A`	默认候选，保留 same-lock anchor	TPS +3.18%，p99 -5.32%
已实现	`Q/R/C`	压力路径，可配置但默认不施加小 Q	小 Q fallback-heavy
已实现	`E/N/X`	有界生命周期 hint	防 stale 但不激进缩短
已实现	`P`	默认关闭，可做 stress/ablation	P 无精确最优
规划中	在线信号聚合	用滑动窗口看 pressure 与 stale trend	需要长期负载验证
规划中	profile selector	OLTP/stress/fairness profile 切换	进入 Phase 3B 后统一做
规划中	论文机制图	把 counters 写成 evidence table	Phase 3A-3 已提供数据
不建议	map size 自适应	暂不做默认动态 map 调整	本轮 map fail = 0
不建议	精确整数调参	不声称 P=18 或 Q=24 通用最优	fine search 只支持区间
不建议	频繁调 C	保持简单阻尼	C 敏感性低

推荐配置收敛

Default

`-O 8 -A`

不设置 `Q`

`P=0`

expiry 默认 2s

Stress / Ablation

`Q=24/32/64`

`C=5/10ms`

`P=8/12/24`

Avoid as Default

`Q<=16`

频繁改 `C`

声称 `P=18` 通用最优

最终 heuristic

$$\text{default}: \quad \textit{same-lock anchor} + \textit{bounded lifecycle} + \textit{counters} - \textit{small queue cap}$$

研究问题与实验结果

研究问题	实验依据	结果
参数阈值经验性强	formal + fine search + counters	存在稳定区间，采用有界启发式
多热点锁锚点失衡	multi-hot 1–64 locks，zero-progress=0	默认 -A 不触发多热点失控
1024-entry map 容量风险	coverage/multihot 全部 map fail=0	本轮范围内不是瓶颈，后续可扩压力
机制证据间接	locality/fallback/stale/pressure 表	用 counters 解释 TPS/p99
运行时 stall 风险	finite boost budget + kworker local path	作为 Phase 3B 公平性前提继续展开
粗扫漏掉中间点	Q24, C3, P18/P20/P24 已补	结果呈平台区间，无单点最优证据

实验结论与限制

已验证结果

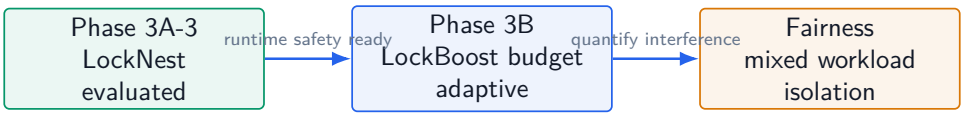
- LockNest adaptive 是有界 anchor-control policy。
- `-O 8 -A` 在本机 256-thread OLTP 正式重复不劣化。
- locality/fallback 计数器记录解释了小 `Q` 的退化。
- 多热点锁没有 map failure 或 zero-progress。

适用限制

- `P=18` 和 `Q=24` 未显示通用最优性。
- 尚无证据将默认收益归因于 finite queue cap。
- 本轮实验仅覆盖当前硬件。
- 多租户公平性尚待验证。

结论对应当前硬件、参数范围与工作负载；跨平台效果和多租户公平性需要独立实验。

从 Phase 3A-3 到 Phase 3B



Phase 3A-3 验证了 LockNest 的锚点机制；Phase 3B 将研究 owner boost 的预算、自适应强度、公平性和混合负载隔离。

Backup: 完整 fine-search 表

Kind	Profile	TPS	p99 ms	failures
Q	q128	4449.89	158.63	0
Q	q64	5201.28	123.28	0
Q	q32	5104.71	127.81	0
Q	q24	5255.63	127.81	0
Q	q12	4411.82	161.51	0
C	c2	4392.36	158.63	0
C	c3	4449.93	164.45	0
C	c8	4518.70	153.02	0
C	c10	4812.70	142.39	0
C	c15	4328.77	158.63	0
expiry	e3000	4693.13	144.97	0
expiry	e4000	4353.06	161.51	0
expiry	e8000	4455.21	158.63	0
N	n750	4387.49	164.45	0
N	n1500	4603.66	147.61	0
P	p8	4837.93	139.85	0
P	p12	4749.17	142.39	0
P	p18	4200.17	170.48	0
P	p20	4520.24	155.80	0
P	p24	4805.34	139.85	0
P	p48	4280.78	167.44	0

Backup: 关键原始文件

文件	用途
results/phase3a3_locknest_20260731_1435_budget/formal_repeats.csv	正式重复
results/phase3a3_locknest_20260731_1435_budget/mechanism_evidence.csv	机制证据
results/phase3a3_locknest_20260731_1435_budget/multihot_microbench_summary.csv	多热点锁实验
results/phase3a3_locknest_20260731_1435_budget/fine_search.csv	细粒度搜索
eurosys_locknest_phase3a3_experiment_report.md	中文完整实验报告

复核命令：全结果目录扫描未发现 runnable task stall、scx_bpf_error、failed to run、Traceback、ERROR、EXIT:。