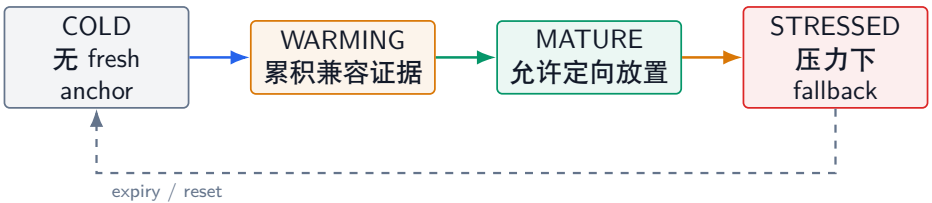
# Phase 3A-4: LockNest Anchor Maturity

## 锚点成熟度、失效边界与论文级无退化证据




结论：M4 通过正式 no-regression gate，但默认仍保持 maturity=off。

# 一句话结论

| -1.69% | -2.97% | 0 | off |
| --- | --- | --- | --- |
| M4 TPS vs off | M4 p99 vs off | map failure / underflow | 最终默认 profile |

**机制验证**： LockNest 可以在重复兼容证据出现前延迟 anchor-directed placement；未成熟、过期或受压锚点都只触发现有 fallback，不阻塞 runnable task。

**决策克制**： static M=4 已通过正式数据库门禁，但没有跨 workload 的稳定收益证据，因此作为可选 profile/消融，而不是默认性能优化。

# 核心问题：计数存在，但生命周期语义缺失

## 原有 `handoff_seq`

$$H \leftarrow H + 1$$

- lifetime diagnostic counter
- anchor 重建后仍持续增长
- 不区分 source strength
- 不能表达重新 warm-up

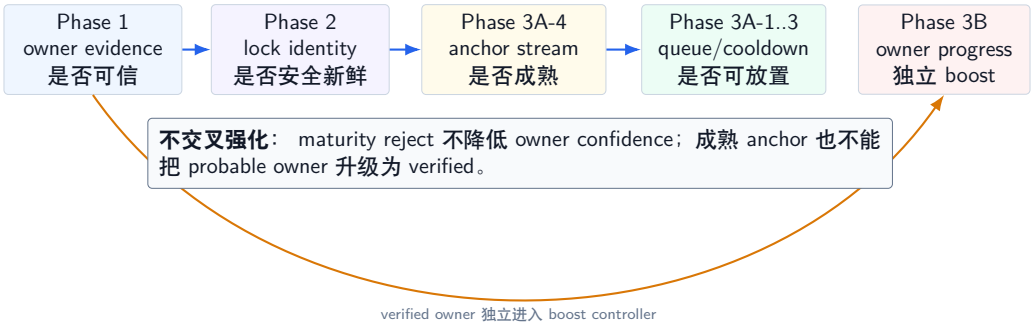
## 需要的策略状态

$$M = \text{current anchor-lifecycle evidence}$$

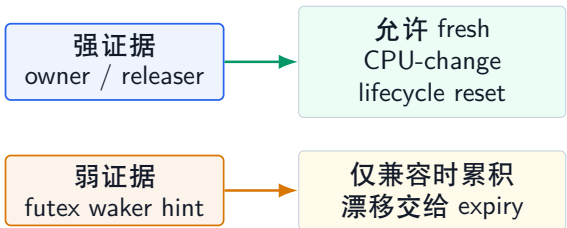
- 可 reset、可饱和
- 与 freshness/source/CPU 兼容性绑定
- 只控制 placement 权限
- 不声称检测 allocator generation

研究问题不是“更新次数是否达到 10”，而是“当前锚点证据流是否足够稳定，值得改变 successor placement”。

# 与已有 Phase 的职责分离



# 设计原则：证据强度约束动作强度



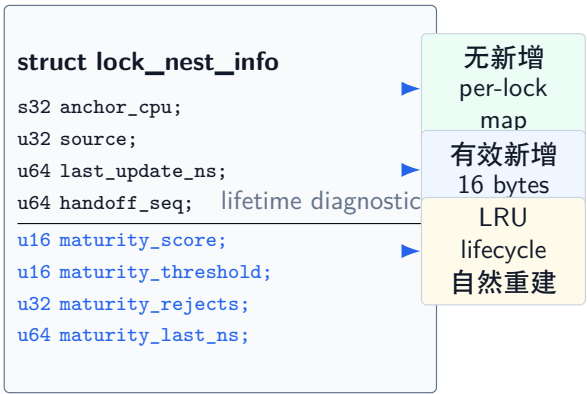

一次弱 waker CPU 变化不能证明 holder topology phase shift

## 安全退化

- 未成熟：prev-CPU/default
- queue pressure：cooldown/fallback
- stale：删除后重新 admission
- cpumask 不允许：default

所有 maturity 拒绝只影响优化机会，不影响任务可运行性。

# 最小数据结构：复用 per-lock state




| 字段 | 作用 |
|---|---|
| score | 当前 lifecycle 饱和证据 |
| threshold | static/adaptive gate |
| rejects | fallback 与 adaptive feedback |
| last_ns | 兼容更新窗口 |

maturity epoch 是调度器内部 evidence lifecycle，不是 mutex generation。

# 更新规则与兼容条件

## 饱和累积

$$M_{n+1} = \min(M_{\max}, M_n + w(s))$$

$$w(s) = \begin{cases} 2, & s \in \{\text{owner,releaser}\} \\ 1, & s = \text{futex-waker} \end{cases}$$

## 放置门

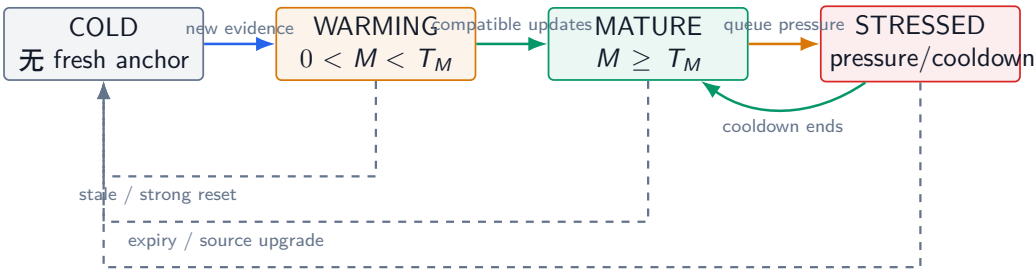
$$\text{admit}_{anchor} = [M \geq T_M]$$

## compatible evidence

$$\begin{aligned} C = (&key' = key) \\ &\wedge (cpu' = anchor_cpu) \\ &\wedge (\Delta t \leq W_M) \\ &\wedge strength(s') \geq strength(s) \end{aligned}$$

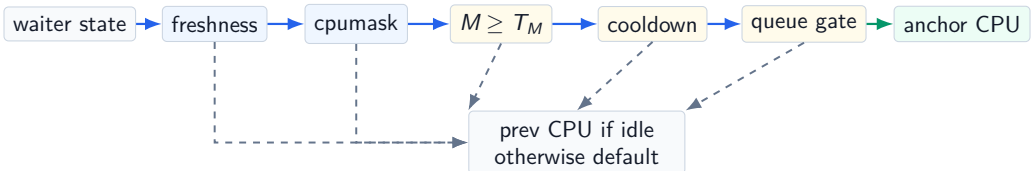
- static: $w = 1$，便于解释旧计数语义
- source/adaptive: 强证据权重更高
- 默认窗口 follow-expiry

# 锚点生命周期状态机




WARMING 和 STRESSED 都继续调度；区别只是 directed placement 被抑制并进入既有 prev-CPU/default fallback。

# Placement pipeline：maturity 只是一道前置门




顺序保证 counters 可区分“state 过期、CPU 不允许、证据未成熟、锚点受压”，避免把所有 fallback 混成一个原因。

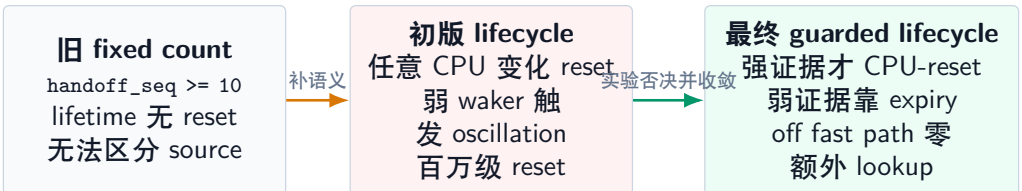
# 四种 profile：实现完整，默认选择保守

| Profile | 更新规则 | 放置门 | 研究用途 | 默认 |
|---|---|---|---|---|
| off | 不更新 maturity | 恒通过 | Phase 3A-3 兼容基线 | 是 |
| static | $M \leftarrow M + 1$ | $M \geq T_M$ | 阈值/旧 `-m10` 语义消融 | 否 |
| source | $w_{strong} = 2, w_{weak} = 1$ | 分 source threshold | 证据强度消融 | 否 |
| adaptive | source weight + $T_M$ 在线调整 | $T_M \in [2, 16]$ | phase/noise 候选 | 否 |

`off` 在 BPF 热路径首分支返回，不 lookup 额外 map，也不执行 maturity gate。

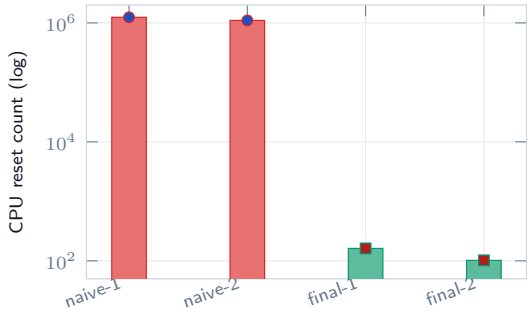
实现 profile 不等于把 profile 写成默认；默认必须由正式重复和机制证据共同决定。

# 代码优化过程：从计数器到有边界的策略




**研究方法**：不把更复杂的规则天然视为更好；用 reset-storm、正式门禁和不变量数据决定哪些逻辑进入热路径。

# 被否决的策略：弱 waker CPU 漂移立即 reset




| Run | CPU resets |
|---|---|
| naive-1 | 1,242,239 |
| naive-2 | 1,100,379 |
| guarded-1 | 162 |
| guarded-2 | 102 |

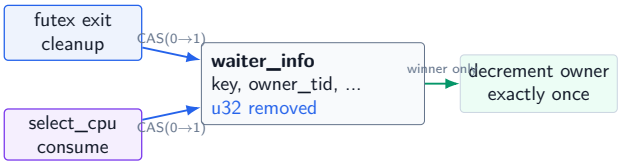
## 原因与最终规则

pthread mutex 的普通 waker 会在 waiter CPU 间轮转；CPU 变化不等价于 holder 拓扑改变。

- strong owner/releaser: 可 reset
- weak waker: 不 reset
- weak drift: expiry/fallback

将错误 reset 降低约四个数量级。

# 并发清理修复：waiter-local 原子 claim




cmpxchg(removed,0,1) 阻止双重 decrement 与伪 underflow

## 修复前

两条路径可能同时清理同一 waiter，owner waiter count 被重复扣减。

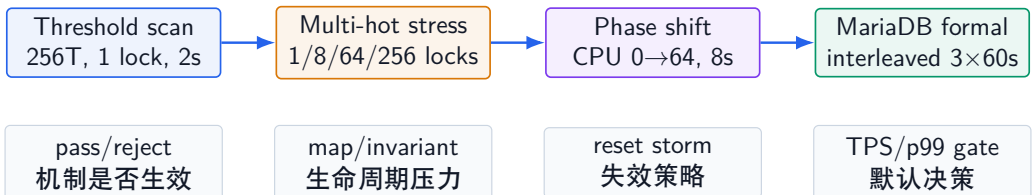
## 修复后

`map_update_fail=0`

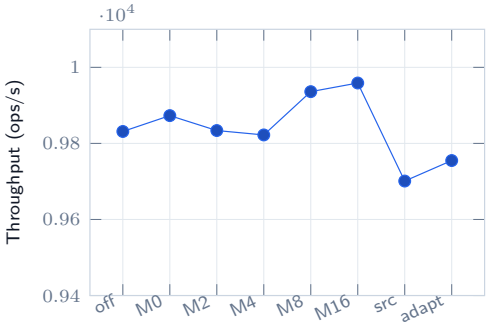
`counter_underflow=0`

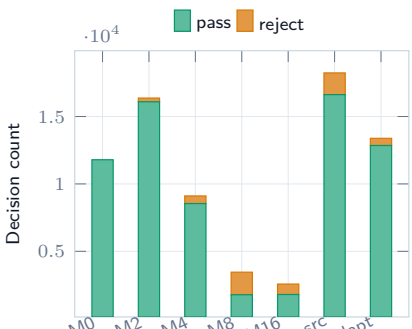
多热点全部正常退出。

# 实验设计：四层证据，而非单点 TPS



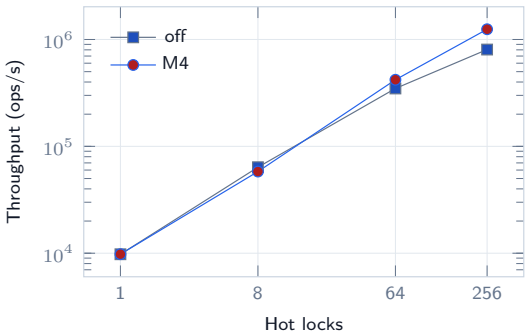
# 阈值扫描：M4 位于可解释的中间区间




单次 2s 扫描只用于机制/候选区间，不用于宣称 1–2% 的性能优劣。

# 多热点锁：warming 压力增长，但状态保持安全




| Locks | M4 reject | invariant |
|---|---|---|
| 1 | 1,097 | pass |
| 8 | 3,119 | pass |
| 64 | 15,739 | pass |
| 256 | 26,408 | pass |

所有 case：map failure=0、underflow=0、无 stall。

各点单次受控 run，只作为 safety/shape evidence。

# Phase shift：最终规则避免 re-anchor oscillation

## 受控 workload

64 threads，1 pthread mutex，100 us critical section；8 s 中点将 owner 从 CPU 0 迁到 CPU 64。

**148,194**
M4 mean ops/s

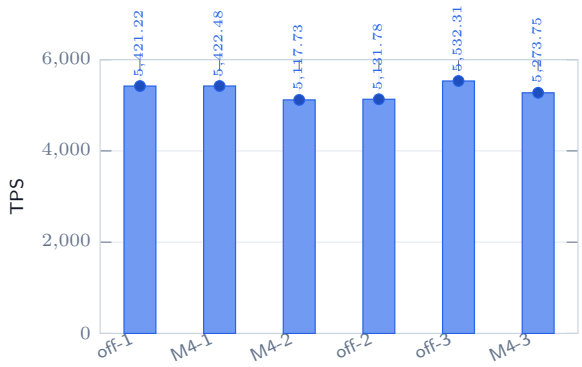
**512 us**
M4 mean p99

这是 safety-only evidence，不将 M4 与 off 的单组差值写成性能结论。

| Policy/run | CPU resets | zero progress |
|---|---|---|
| naive reset 1 | 1,242,239 | – |
| naive reset 2 | 1,100,379 | – |
| guarded M4 1 | 162 | 0 |
| guarded M4 2 | 102 | 0 |

弱证据漂移不再触发 reset；强 evidence 仍可重建 lifecycle。

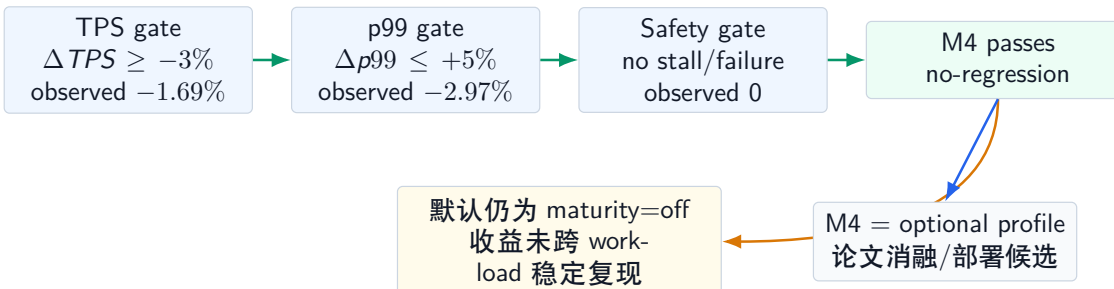
# 正式 MariaDB：M4 通过无退化门禁




| Mean | off | M4 |
|---|---|---|
| TPS | 5361.77 | 5271.32 |
| p95 ms | 94.74 | 94.14 |
| p99 ms | 128.72 | 124.90 |
| failures | 0 | 0 |

**交错顺序**：off, M4, M4, off, off, M4；每次 60 s。

# 预注册门禁与最终选择




“通过 gate”证明没有破坏主线；“进入默认”还需要稳定、可解释的跨 workload 收益。

# 优化方案对比

| 方案 | 策略状态 | 热路径成本 | Reset 语义 | 默认 | 主要风险 |
|---|---|---|---|---|---|
| safe adaptive | 原有 nest state | baseline | freshness/expiry | 是 | 瞬时事件较快 admission |
| old `-m10` | lifetime seq | compare | 无 | 否 | 历史累积污染策略语义 |
| static maturity | score+threshold | add+compare | lifecycle | 否 | threshold 需实验 |
| source-aware | score+source weight | 少量分支 | source-aware | 否 | 复杂度上升 |
| adaptive maturity | per-lock threshold | O(1) update | lifecycle | 否 | feedback 可能振荡 |

保留：可关闭、可归因、fallback 安全、M4 通过正式门禁。

拒绝：弱 waker CPU drift 触发 reset、按最高单次 TPS 选参数。

# 论文证据链与 Claim 边界

## 可以主张

- repeated compatible evidence 前可延迟定向放置
- reject 安全退化到既有 fallback
- weak-waker drift 不触发 re-anchor
- M4 通过 MariaDB no-regression gate
- 多热点无 map failure/underflow/stall

## 不能主张

- maturity 检测 mutex free/realloc generation
- M4 在所有 workload 提升性能
- waker hint 精确等于 lock handoff
- 多热点表给出精确 LRU eviction 数
- maturity 替代 Phase 2 identity/freshness

论文主线应强调“可证伪的 advisory lifecycle gate”，而不是把内部计数包装成对象代际追踪。

# 最终配置与阶段结论

## 论文/部署默认

```
scx_lockcoop   -O 8 -A --boost-profile adaptive
--anchor-maturity-profile off --evidence-scope all
```

## M4 消融/可选 profile

```
--anchor-maturity-profile static --anchor-maturity-threshold 4
```

Phase 3A-4 已完成机制实现、错误策略排除与并发清理修复，并进行了阈值、多热点、阶段切换和数据库实验。结果支持将该机制保留为可选配置，尚不足以替换默认策略。

Sources: eurosys_locknest_phase3a4_experiment_report_20260801.md and archived CSV/JSON artifacts.