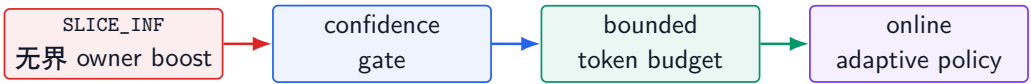
# Phase 3B: LockBoost

## 自适应 Boost 控制

从无限时间片到可解释的 owner-progress 控制器




**论文主线**：`scx_lockcoop -O 8 -A --boost-profile adaptive`

最终结果：MariaDB 5404.45 TPS，p99 126.41 ms；所有正式 runner 结束后 sched_ext=disabled。

# 一句话结论

| 5404.45 | 126.41 ms | +0.19% | +1.15% |
|---|---|---|---|
| adaptive TPS | adaptive p99 | TPS vs Phase 3A-3 | p99 vs Phase 3A-3 |

**实现与验证**： verified-owner gate、token budget、动态 threshold、long-CS guard、active revoke 与 fast-progress guard 均已实现，并通过计数器记录验证。

**Claim 边界**： adaptive 在真实 mixed OLTP 中改善 victim 尾延迟；合成 owner-preempt workload 中不保证每个 percentile 都优于 inf。

# 为什么给持锁者额外运行时间？

## 错误的强假设

- 任意 futex wake 都知道 owner。
- 发现 waiter 就给某个 task 无限时间片。
- owner 长时间运行总能提升系统吞吐。

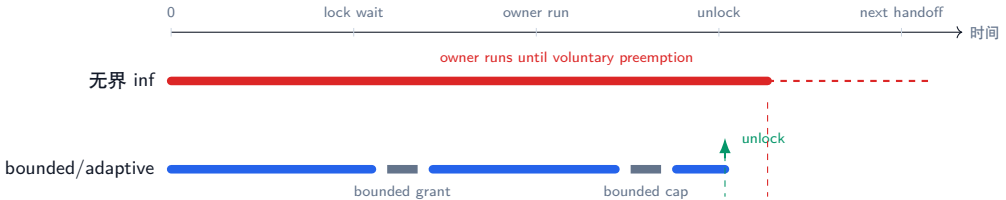
错误 owner + 无界 boost = 将观测误差放大为调度干扰。

## Phase 3B 的控制对象

- LockBoost 只消费 verified owner evidence。
- waiter fan-in 说明 owner-progress 的潜在收益。
- owner runnable delay 说明 owner 是否真的被调度延迟。
- unlock interval 说明这把锁是否已经自我快速前进。

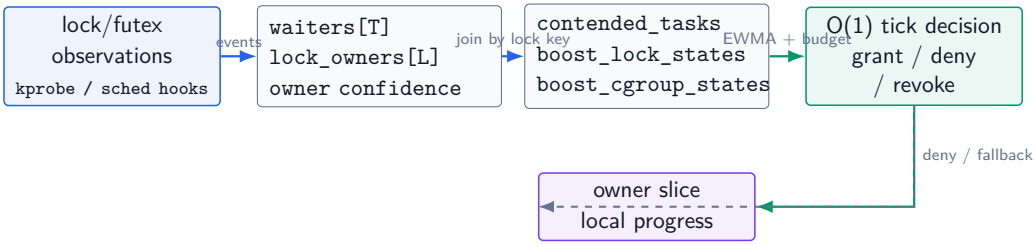
Boost 不是“发现竞争就延长时间片”，而是“证据足够且 owner 确实被延迟时才有界推进”。

# Owner-progress 时间线：为什么需要 bounded boost




无界 boost 追求 owner progress，但可能持续压制旁路任务；有界 boost 把 owner-progress 转化为可预算、可撤销、可解释的调度动作。

# 系统架构：观测、状态与动作




Fast path：已有证据时只做 hash lookup、confidence gate、budget gate 和有限 slice 更新；诊断 counters 单独采集，不污染正式性能路径。

# 数据结构：把“谁在等谁”变成可预算状态

## owner state

`contended_tasks[tid]`

waiter count
active lock key
confidence
delay EWMA
adaptive threshold
task token
revoke/cooldown

## lock state

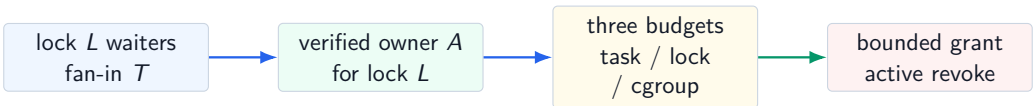
`boost_lock_states[key]`

lock token
fan-in EWMA
unlock interval EWMA
boost efficiency
waiter unblocked
fast-progress guard

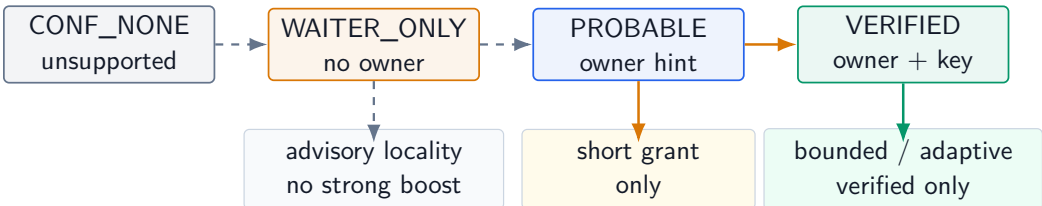
## cgroup state

`boost_cgroup_states[cgid]`

cgroup token
boost count
deny count
mixed workload accounting
minimum isolation closure



# Confidence gate：强动作必须匹配强证据




默认 gate=‘VERIFIED‘。普通 futex wake 不是 owner proof；低置信事件可支撑 LockNest locality，但不会进入强 owner-progress。

# 三层 token budget：限制连续占用，而不是追求全局最优

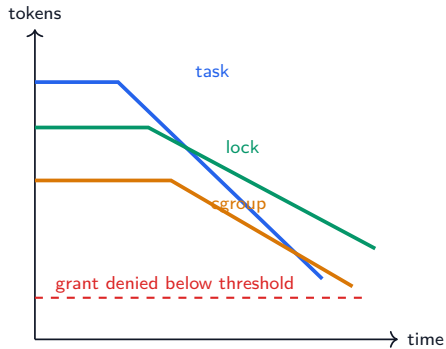
## 滑动补充公式

$$cap_i = W \cdot p_i/100$$

$$token_i(t) = \min\left(cap_i,\ token_i(t_0) + \frac{cap_i(t - t_0)}{W}\right)$$

$$allow \iff \bigwedge_{i \in \{task, lock, cgroup\}} token_i \geq grant$$

| bucket | 作用 | 最终默认 |
|---|---|---|
| task | 防止一个 owner 连续占用 | 20% |
| lock | 防止一个热点锁支配系统 | 40% |
| cgroup | mixed workload 最小隔离 | 40% |



# 自适应 threshold 与 fast-progress guard

## threshold 更新

$$T \leftarrow \mathit{clamp}(T, 2, 16)$$

$$\begin{aligned} \mathit{debt} \vee \mathit{longCS} &\Rightarrow T \uparrow \\ D > \mathit{target} \wedge F \geq T &\Rightarrow T \downarrow \\ F < T \wedge D < \mathit{target}/2 &\Rightarrow T \uparrow \end{aligned}$$

## EWMA signals

$$D = \mathit{EWMA}(\mathit{owner\ runnable\ delay}, 1/8)$$
$$F = \mathit{EWMA}(\mathit{waiter\ fan\text{–}!in}, 1/8)$$

## fast-progress guard

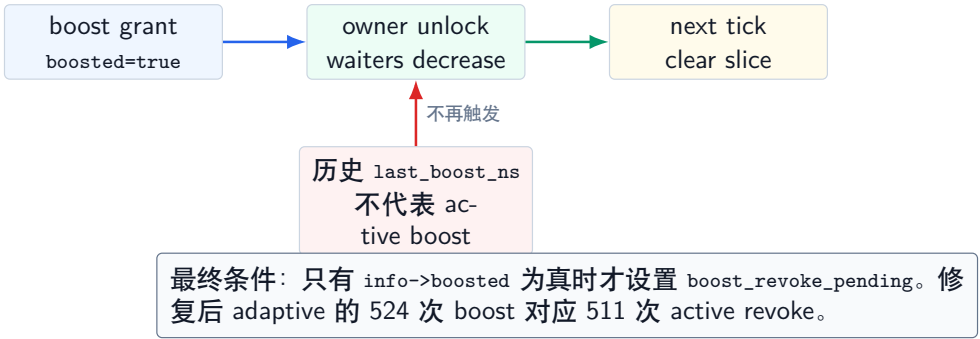
$$U_L = \mathit{EWMA}(\mathit{unlock\ interval}_L, 1/8)$$

$$U_L < \mathit{target_delay}/8 \Rightarrow \mathit{boost}(L) = 0$$

同一锁已经快速 unlock 时，继续 boost 只增加调度干扰；lock-level EWMA 跨 owner 保留，避免 task-local threshold 每次重置。

短锁结果：cs=0 下 adaptive 实际 boost=0；cs=100 us 下仍保留有限 boost，吞吐仅比 none 低 0.13%。

# Unlock revoke：从 stale state 到 active-only revoke



# Profile 对比：控制强度与风险边界

| profile | owner evidence | grant | cap | budget | SLICE_INF | 用途 |
|---|---|---|---|---|---|---|
| none | optional | 0 | 0 | off | no | mechanism control |
| short | verified/low risk | 500 us | 1 ms | off | no | low-risk progress |
| bounded | verified | 1 slice | 2 slices | off | no | static safety baseline |
| adaptive | verified | 1 ms | 4 ms | 20/40/40% | no | paper candidate |
| inf | verified | infinity | infinity | off | explicit | risk ablation |

adaptive 的关键不是把 grant 变大，而是把 grant 置于 confidence、budget、delay、unlock interval 和 cooldown 的共同约束下。

inf 只做上界风险对照；论文默认配置和推荐部署均不启用它。

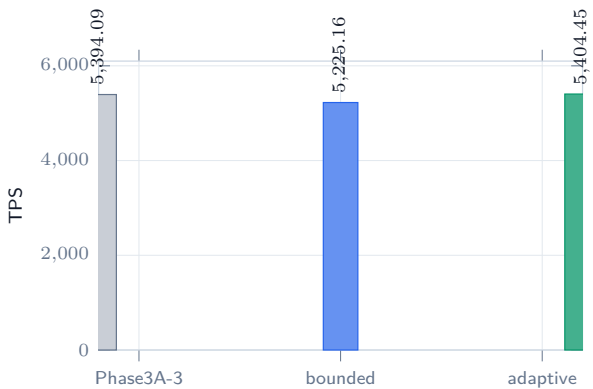
# 实验平台与最终协议

| 项目 | 设置 |
|---|---|
| CPU | 2-socket Xeon Platinum 8375C |
| CPU topology | 64 cores / 128 logical CPUs |
| NUMA | 2 nodes, SMT enabled |
| Kernel | Linux 6.17.0-35-generic |
| DB | MariaDB + Sysbench OLTP RW |
| DB threads | 256 |

| 阶段 | 最终样本 |
|---|---|
| formal pair | 6 runs, B-A-A-B-B-A |
| mechanism | 5 profiles, stats-only |
| parameter | 25 points × 2 |
| fairness | 2 CS × 5 profiles × 5 rounds |
| mixed | 3 profiles × 3 runs |
| short lock | 15 interleaved + 3 counters |

性能阶段关闭 diagnostic-only probes；机制阶段单独使用 `--stats-only`，避免把 instrumentation overhead 混入 TPS/p99。

# 正式 MariaDB：adaptive 通过性能门槛

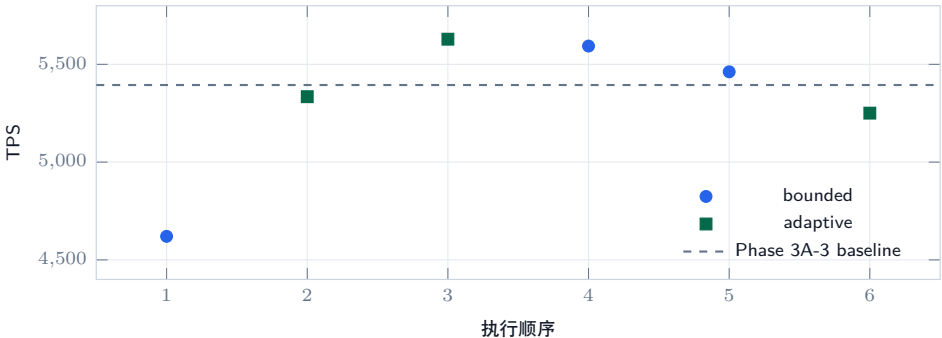



| profile | TPS | p99(ms) |
|---|---|---|
| Phase 3A-3 | 5394.09 | 124.97 |
| bounded | 5225.16 | 132.67 |
| adaptive | **5404.45** | **126.41** |

相对历史基线：TPS +0.19%，p99 +1.15%。

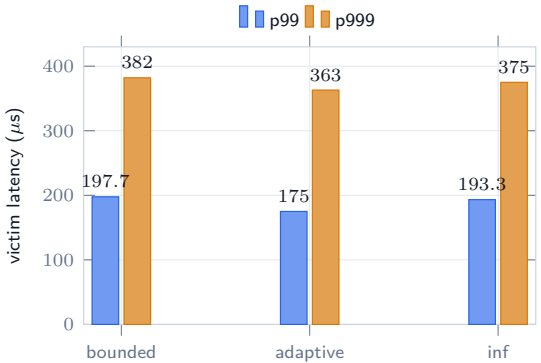
相对 bounded：TPS +3.43%，p99 -4.72%。

# 正式 MariaDB：六个交错样本，而不是挑一个最好值




交错顺序 B-A-A-B-B-A 将 profile 差异与机器随时间的波动分离；adaptive 的三次均值为 5404.45 TPS，CV 3.67%。

# Mixed OLTP + cyclictest：adaptive 的真实隔离取舍

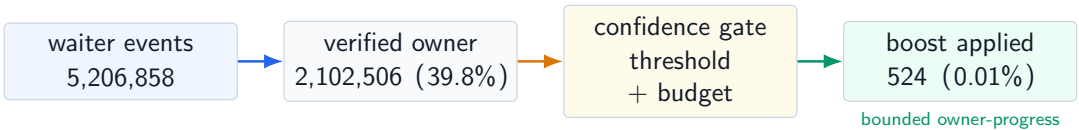



| profile | TPS | DB p99 | victim p99 |
|---|---|---|---|
| bounded | 5641.83 | 224.91 | 197.7 |
| adaptive | 5595.68 | 246.67 | **175.0** |
| inf | 5338.26 | 238.32 | 193.3 |

adaptive 相对 bounded：主 TPS -0.82%，DB p99 +9.67%，但 victim p99 -11.5%。

adaptive 相对 inf：TPS +4.82%，victim p99/p999 -9.5%/-3.2%。

# 机制证据：从 5.2M waiter events 到 524 次 boost




boost efficiency：10,737 waiters unblocked / 524 boost = 20.5 waiters per boost；active revoke=511，long-CS deny=21。

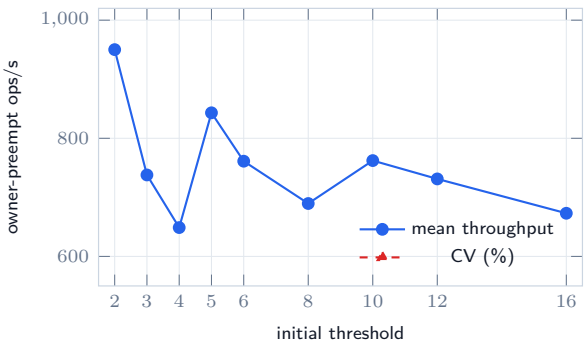
owner miss '3,175,230' 不是错误归因；它们被 gate 阻断强 boost，仍可由 LockNest 使用 advisory locality evidence。

# 机制表：adaptive 在做什么，而不是只看 TPS

| 指标 | none | bounded | adaptive | inf | adaptive 的读法 |
|---|---|---|---|---|---|
| boost applied | 0 | 17,384 | 524 | 6,372 | 只对高价值 owner 动作 |
| active revoke | 0 | 17,315 | 511 | 6,205 | 与 active boost 同量级 |
| waiters unblocked | 0 | 64,498 | 10,737 | 62,635 | 约 20.5 / boost |
| owner delay avg | 0 | 0 | 446 us | 0 | adaptive 的反馈信号 |
| threshold up/down | 0/0 | 0/0 | 14,600/48 | 0/0 | 压力下趋向保守 |
| long-CS denied | 0 | 0 | 21 | 0 | cooldown 触发 |
| map update fail | – | – | 23,397 | – | stats-only evidence lower bound |

adaptive 不是“boost 越多越好”：它以少量、可撤销的 grant 换取 waiter release，并用 threshold/cooldown 抑制持续干扰。

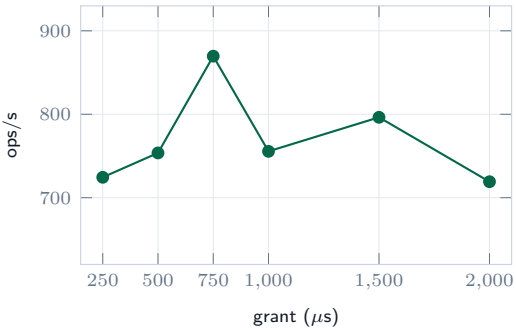
# 参数敏感性：threshold 不存在无条件最优点

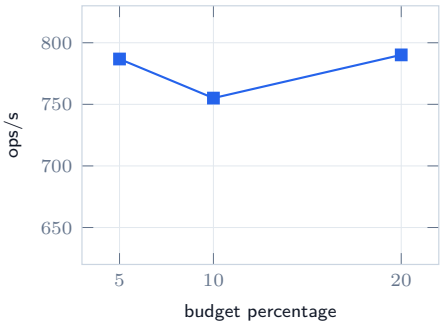



| T | ops/s | CV |
|---|---|---|
| 2 | 950.1 | 7.39% |
| 4 | 648.8 | 24.90% |
| 8 | 689.6 | 1.66% |
| 16 | 673.1 | 1.26% |
| 3 | 737.9 | 6.81% |
| 5 | 843.2 | 10.20% |

不能追逐最高单点；T=4 是中间起点，在线规则将它拉向压力适配区间。

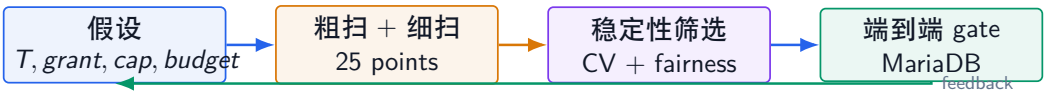
# 参数敏感性：grant / cap / budget 的稳定区间




grant=750 us 的峰值 CV 为 12.06%，cap=3000 us 的峰值 CV 为 77.09%；最终采用 grant=1000 us、cap=4000 us、budget=20/40/40%。

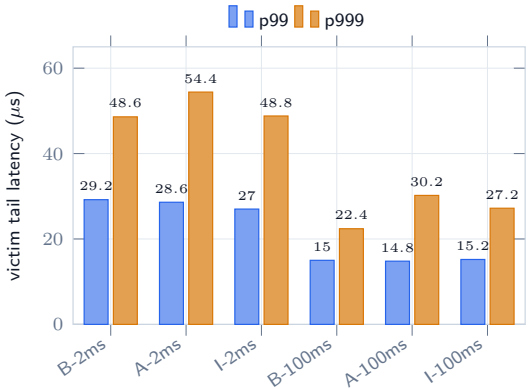
# 参数选择逻辑：先大胆假设，再用稳定性筛选




自动调优不是事后挑最高 TPS；它应避开高方差峰值，并保证 online rule 在参数失调时回到 bounded、安全区间。

最终默认不是微基准最高点，而是“参数空间中间点 + 在线自适应 + 端到端性能 gate”的组合。

# Fairness：有限 boost 换取更高 Jain fairness




| 场景 | adaptive Jain | inf Jain |
|---|---|---|
| 2 ms | **0.9805** | 0.8906 |
| 100 ms | **0.9928** | 0.9923 |

2ms：adaptive 将 Jain fairness 从 0.8906 提高到 0.9805。

严格边界：synthetic workload 的 p999 不保证始终低于 inf。

# 优化对比：从“强推进”到“可部署策略”

| profile | MariaDB TPS | DB p99 | victim p99 | victim p999 | Jain (2ms) | 风险解释 |
|---|---|---|---|---|---|---|
| none | – | – | 25.8 us | 49.4 us | 0.8776 | 不干预，owner progress 弱 |
| bounded | 5641.83 | 224.91 ms | 197.7 us | 382.0 us | 0.9672 | 有界静态推进 |
| adaptive | **5595.68** | 246.67 ms | **175.0 us** | **363.0 us** | **0.9805** | 动态 gate + budget |
| inf | 5338.26 | 238.32 ms | 193.3 us | 375.0 us | 0.8906 | 无界风险上界 |
| Linux default | – | – | – | – | – | 非同等服务水平 baseline |

论文主张：adaptive 是主负载、victim tail 和公平性之间的可解释折中。

不主张：adaptive 在任何 workload、任何 percentile、任何 baseline 上都最优。

# Reviewer concerns：逐项回答

| 研究问题 | Phase 3B 实验依据 |
| --- | --- |
| SCX_SLICE_INF 饥饿 | inf 只作风险对照；adaptive 有 grant/cap/budget/cooldown，mixed 中 victim p99/p999 低于 inf。 |
| 低置信 owner 误 boost | 默认 verified gate；private futex owner miss 不进入强 boost。 |
| 长 critical section | max continuous boost + cooldown；机制样本记录 21 次 long-CS deny。 |
| unlock 后 stale boost | active-only revoke；524 boosts 对应 511 active revokes。 |
| 参数依赖精调 | 25 点扫描 + CV 筛选 + endpoint gate；默认不选择高方差峰值。 |
| 多租户隔离 | cgroup token 可计数、可 gate、可实验；完整生产 SLA 仍是后续工作。 |
| 最坏 fairness guarantee | 不做严格 starvation-free claim；报告 Jain 和 p99/p999 的真实边界。 |

# 实验结论与限制

## 已验证结果

- 有界、置信度约束的 owner-progress controller。
- adaptive 在 MariaDB mixed OLTP 中保持吞吐，并降低 victim p99/p999。
- fast-progress guard 避免短锁误 boost。
- inf 是风险上界，不是默认部署策略。

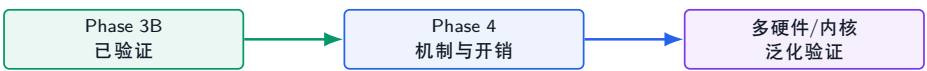
## 适用限制

- 部分工作负载的延迟分位数未优于 inf。
- 尚无严格的无饥饿或最坏等待时间保证。
- cgroup 隔离尚未达到完整生产要求。
- stats-only counters 不提供逐事件无损记录。

Phase 3B 的贡献是把 boost 从一个强动作变成一个受证据、预算和反馈控制的系统机制。

# Phase 3B 验收状态与下一步

| 验收项 | 状态 | 依据 |
| --- | --- | --- |
| 两套调度器 build / attach / detach | PASS | 10-profile smoke，全为 disabled |
| MariaDB no-regression | PASS | 5404.45 TPS，p99 126.41 ms |
| 极短锁保护 | PASS | cs=0 吞吐差 -0.99%，p99 相同 |
| 机制证据 | PASS (bounded) | counters 可解释；map drop attribution 留给 Phase 4 |
| 参数敏感性 | PASS (bounded) | 25 点扫描，默认不追逐高 CV 峰值 |
| fairness / mixed | PASS (qualified) | mixed tail 改善；synthetic p999 非普遍改善 |




Phase 3B 已经不再阻塞后续工作；Phase 4 重点是 map-drop 细分、百万级 kprobe 开销、wakeup-to-run 和直接 handoff 证据。

# Phase 3B: LockBoost adaptive control

Bounded boosting: implementation and evaluation.

