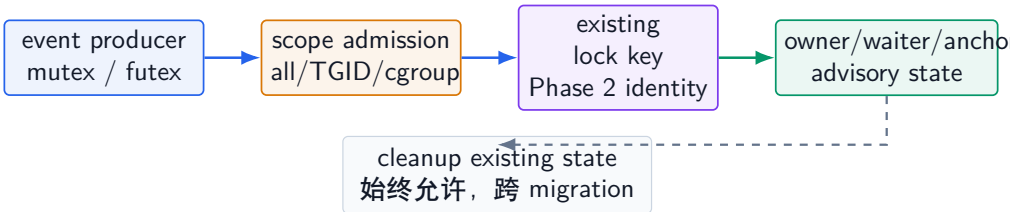
Phase 3C: Generic Evidence Scope

谁可以生产调度证据，而不是谁被调度、锁是谁



结论：scope=all 保持默认；TGID/cgroup 是证据边界与归因接口。

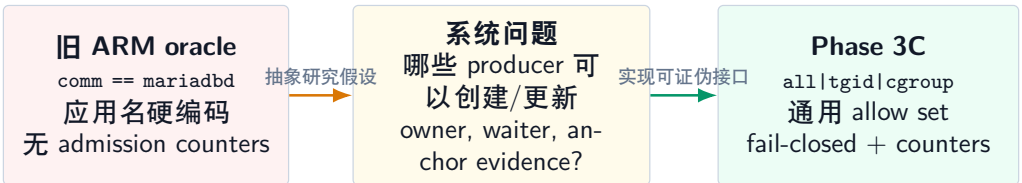
一句话结论

55,105	21.64M	0	all
cgroup admitted	cgroup denied	map failure / underflow	最终默认 scope

正确性验证：out-of-scope producer 不创建新的 lock evidence，但原有 waiter/owner/boost state 的清理不受 scope deny 阻断；迁移后 workload 正常结束。

性能边界：仅允许 MariaDB service、排除 Sysbench clients，使 TPS 从 5,361.77 降至 1,305.56；scope 不是默认性能开关。

从应用特化 oracle 到通用系统接口



Phase 3C 的价值不是复制 `-M`，而是把一次应用特化调优转化为与应用名无关、可配置、可验证的 evidence boundary。

三个概念必须分开

Evidence scope

谁可以生产/更新 advisory evidence ?

$$producer \in allowset$$

Lock identity

两个事件是否属于同一同步对象 ?

$$key = (kind, addr, scope_id)$$

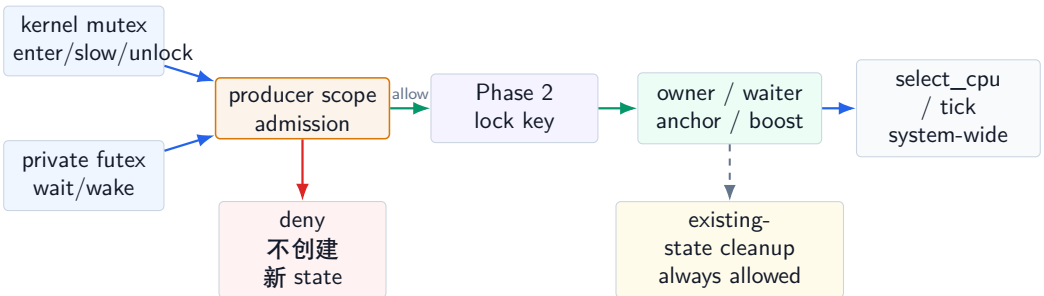
Scheduling isolation

哪些 task **被管理、能用哪些** CPU/**预算** ?

$$p \rightarrow cpus_ptr,\ cgroup\ budget$$

Scope **既不进入** lock key，**也不让** out-of-scope task **脱离** sched_ext **管理，更不是安全沙箱**。

体系结构：scope gate 位于 state mutation 之前



Identity invariant：scope 不改变同步对象身份

Phase 2 lock key 保持不变

$$K = \begin{cases} (\text{kernel}, \mathit{addr}, 0), & \text{kernel mutex} \\ (\text{private futex}, \mathit{uaddr}, \mathit{tgid}), & \text{private futex} \end{cases}$$

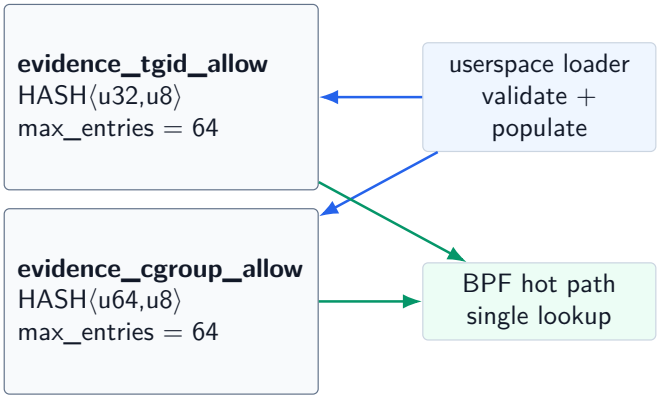
- 不追加 cgroup ID 到 lock key
- task 迁移不拆分同一 lock identity
- private futex 跨进程隔离仍由 TGID key 保证
- cgroup 是 control plane，不是 object generation

Scope 只做事件准入

$$\mathit{event} \xrightarrow{\mathit{scope}} K \rightarrow \mathit{state}$$

scope 配置错误只能损失优化机会，不能造成任务不可运行。

控制面数据结构：固定 allow set，不用 LRU



为什么不是 LRU

allow set 是控制面配置，不能因事件访问模式被自动淘汰。

为什么不复制到每个 state

- 避免扩大高频 map value
- scope 不属于 identity
- cleanup 复用已有 key/TID

用户态接口与 fail-closed 校验

CLI

```
--evidence-scope all|tgid|cgroup
--evidence-tgid PID  (repeatable)
--evidence-cgroup-id ID  (repeatable)
--evidence-cgroup-path PATH  (repeatable)
--evidence-scope-stats
```

cgroup path 经 cgroup v2 filesystem 校验，并解析为 kernfs node ID；运行期由 `bpf_get_current_cgroup_id()` 匹配。

attach 前拒绝

- scoped mode 但 allow set 为空
- TGID/cgroup 参数冲突
- ID=0 或超过 64 entries
- TGID 不存在
- 非 cgroup v2 path

绝不静默回退到 all，避免实验配置错误被掩盖。

默认 fast path：all 不做 map lookup 或 counter write

evidence_allowed(event)

```
if (mode == ALL) return true;

stat_inc(SEEN);
if (mode == TGID)
  lookup(tgid_allow, tgid);
else
  lookup(cgroup_allow, cgid);

if (hit) admitted++;
else denied++;
```

Profile	额外热路径成本
all	rodata mode branch
TGID	PID 提取 + 1 hash lookup
cgroup	helper + 1 hash lookup
stats	per-CPU counter writes

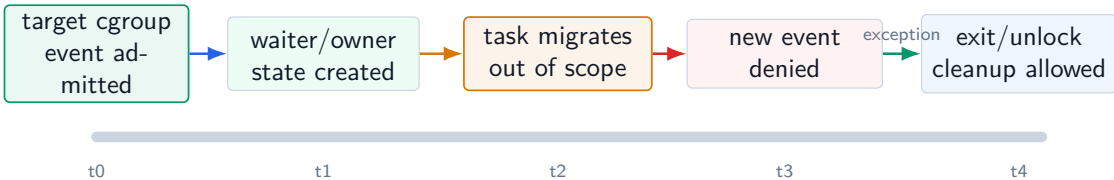
默认行为兼容优先：Phase 3C 不给全系统 event path 增加统计写。

Gate 覆盖：创建受限，消费与清理保持系统级

Event/path	out-of-scope producer	existing state cleanup	备注
mutex enter	不创建 active state	–	return path 只消费 enter state
mutex slowpath	不解析 owner/创建 waiter/nest	–	无新 placement evidence
mutex unlock	不 refresh anchor	允许 owner delete / boost revoke	migration-safe
futex WAIT	不读 pthread owner，不创建 waiter/nest	sys_exit cleanup 允许	private key 不变
futex WAKE	不更新 hint/anchor/unlock EWMA	active boost revoke 允许	action 不重做 scope gate
select/tick	消费已有 state	正常	sched_ext 仍管理全部 task

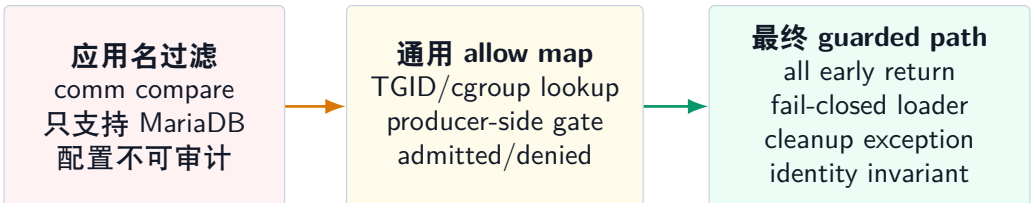
核心不变量：**create/refresh new evidence is scope-gated; cleanup existing dependency is always allowed.**

迁移清理：为什么 deny 不能提前 return



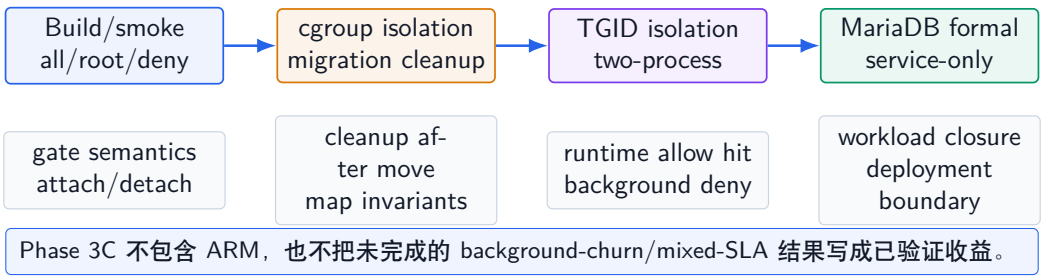
若 unlock/futex-exit 在 scope deny 后直接返回，迁移前创建的 owner/waiter/boost state 会失去清理路径。

代码演化：从硬编码过滤到通用 admission layer

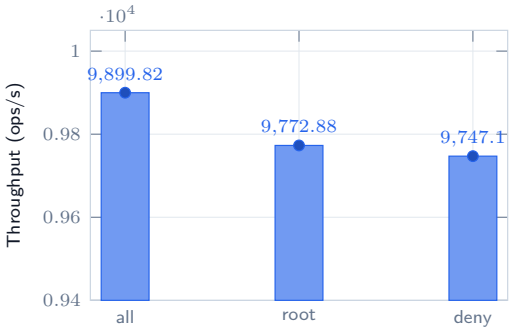


没有在 BPF 中自动猜测 workload closure，也没有按 TPS 在线选择 scope；
复杂度被限制在 mode、allow set、stats 三类控制参数。

实验矩阵：接口正确性优先于性能故事



Admission/denial micro：计数语义与安全退化

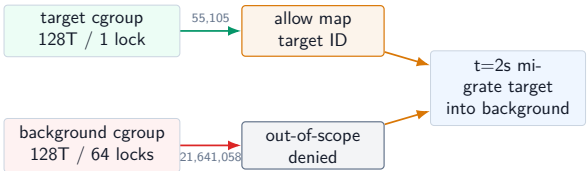


mode	seen	admit	deny
all	0	0	0
root ID 1	55,176	194	54,982
nonexistent	53,402	0	53,402

全部 workload 正常完成；deny-all 只关闭优化证据，不关闭调度。

root 不是 target workload scope，只验证 map gate。

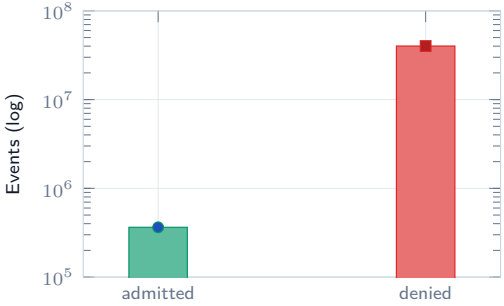
Cgroup isolation + migration：清理路径成立



Metric	Result
target/background rc	0 / 0
map failure	0
counter underflow	0
target procs after move	empty
final sched_ext state	disabled
cleanup_out	11,355,513

cleanup_out 是成功清理的 transient dependency 次数，不是 persistent stale-entry 数。

TGID isolation：allow set 确实在运行期生效

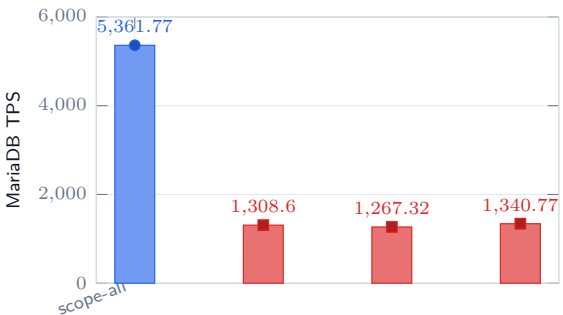


Metric	Result
target TGID	3,698,985
admitted	364,034
denied	40,118,587
target/background rc	0 / 0
map fail/underflow	0 / 0
final state	disabled

admitted 与 denied 同时非零，证明 loader 配置、BPF lookup 和 workload identity 全链路命中。

TGID 会复用，适合 controlled/短期 profile；长期部署优先 cgroup。

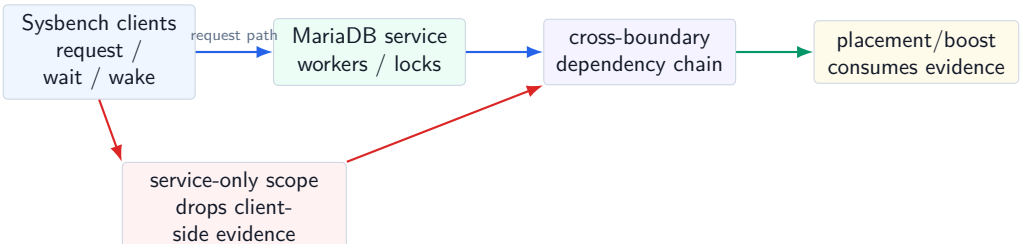
正式负结果：service-only scope 破坏端到端 evidence closure



Mean	TPS	p99 ms
scope=all	5361.77	128.72
service-only	1305.56	597.77

TPS -75.65%; p99 +364.4%。这不是 map collision 或 attach failure。

为什么 service-only scope 会失败



优化与接口方案对比

方案	通用性	热路径	生命周期	性能证据	决策
comm oracle	单应用	string compare	无通用 cleanup 语义	ARM 排障观察	仅 oracle
scope=all	全系统	early return	现有 lifecycle	当前主线 5361.77 TPS	默认
TGID allow set	单/多进程	TGID+hash	exit cleanup	isolation 成立	实验/短期
cgroup allow set	service/workload	helper+hash	migration cleanup	service-only 负结果	部署接口
auto classifier	未实现	高复杂度	难验证	无	不建议

保留：通用 allow set、fail-closed、all fast path、cleanup exception。

拒绝：进程名硬编码、scope 进入 lock key、按 TPS 在线猜 scope。

部署决策表

Profile	适用场景	必要条件	论文/默认角色
all	通用端到端部署	无额外 scope 配置	**默认**
TGID	controlled benchmark、临时单进程	runtime PID 有效、及时撤销	正确性/消融接口
cgroup	显式 workload/service 集合	allow set 覆盖完整 dependency closure	部署归因接口
service-only	当前 MariaDB server cgroup	排除了 Sysbench client	**非性能候选**

cgroup scope 的稳定 identity 优于 TGID，但“稳定”不等于“自动完整”；是否覆盖 request path 必须由部署者与机制 counters 验证。

论文 Claim 边界

可以主张

- 通用 TGID/cgroup evidence admission
- scope gate 位于 owner/waiter/anchor mutation 前
- scope 不改变 lock identity
- out-of-scope producer 不创建新 state
- cleanup 能跨 cgroup migration 完成

不能主张

- scope 是安全沙箱或调度隔离
- 任意 service-only scope 提升性能
- 自动发现完整 request path
- cgroup ID 替代 private-futex TGID identity
- 当前结果代表 ARM/VM/多 NUMA 平台

最强且准确的表述是：scope 控制 evidence production；调度与 cleanup 仍保持 system-wide。

最终配置与阶段结论

论文/部署默认

```
scx_lockcoop -O 8 -A --boost-profile adaptive
--anchor-maturity-profile off --evidence-scope all
```

受控 cgroup profile 示例

```
--evidence-scope cgroup --evidence-cgroup-path /sys/fs/cgroup/...
```

Phase 3C 已完成接口实现与正确性验证，覆盖通用控制面、运行期 admission/denial、跨 migration 清理与默认 fast path。性能实验表明，缩小 scope 可能降低吞吐，因此将其作为可选配置。

Sources: eurosys_phase3c_evidence_scope_experiment_report_20260801.md and archived CSV/JSON artifacts.